Análisis Exploratorio y Perfilado desde la Ciencia de Datos de La Calidad del Aire Global

F.E. Guardado, D.H. Méndez, A.X. Landaverde, R.E. Escobar

***Resumen / Abstract*—El monitoreo y evaluación de la calidad del aire representa un desafío fundamental para la salud pública y la comprensión del cambio climático [1], [8]. Este proyecto aplica un flujo riguroso de Ciencia de Datos para llevar a cabo el perfilado inicial, la auditoría de calidad y el Análisis Exploratorio de Datos (EDA) sobre un conjunto de datos global de 30,450 observaciones que abarca mediciones de contaminantes atmosféricos ($PM_{2.5}$, PM_{10}, NO_2, SO_2, CO, O_3) y variables meteorológicas (temperatura, humedad y velocidad del viento). La metodología comprende la implementación de una copia inmutable del dataset, la depuración de redundancias y la imputación fundamentada de faltantes, así como el análisis probabilístico univariado y multivariado [4], [6].**

Resultados y hallazgos clave:

- **Saneamiento y preservación de varianza: Tras normalizar texto en `City/Country`, se identificó y depuró un 45.64 % de duplicidad exacta (13,897 registros), más un remanente de duplicados parciales por clave de negocio (*City+Country+Date*), logrando recuperar un conjunto continuo de 5,075 observaciones con 0.00 % de outliers extremales fuera de los límites de Tukey [4] y una retención de varianza estocástica superior al 97.5 %.**
- **Cumplimiento crítico de guías de la OMS: Más del 93.17 % de los días monitoreados superan el umbral diario de $PM_{2.5}$ de la OMS [1], seguido de un 82.92 % para PM_{10} y un 79.34 % para NO_2.**
- **Inexistencia del "efecto fin de semana": Las pruebas no paramétricas de Mann-Whitney U confirmaron que las concentraciones de NO_2, CO y $PM_{2.5}$ no varían significativamente entre días laborales y fines de semana ($p > 0.18$), demostrando emisiones continuas e ininterrumpidas.**
- **Independencia meteorológica: Se observó una correlación muy débil entre factores climáticos y contaminantes ($|r_s| < 0.03$), así como entre $PM_{2.5}$ y PM_{10} ($r = 0.018$).**

Conclusión: Este estudio proporciona un diagnóstico integral del estado de los datos, demostrando que la contaminación ambiental global responde a patrones antropogénicos de fondo y preparando un dataset depurado y confiable para su posterior modelado predictivo.

***Index Terms*—Ciencia de Datos, Calidad del Aire, Análisis Exploratorio de Datos (EDA), Perfilado de Datos, Contaminantes Atmosféricos, OMS.**

I. Introducción

La contaminación del aire constituye uno de los mayores desafíos ambientales y de salud pública a nivel global en el siglo XXI. De acuerdo con la Organización Mundial de la Salud (OMS), la exposición a material particulado en suspensión ($PM_{2.5}$ y PM_{10}) y a gases contaminantes como el dióxido de nitrógeno (NO_2), dióxido de azufre (SO_2), monóxido de carbono (CO) y ozono troposférico (O_3) está directamente asociada con el incremento en la morbilidad y mortalidad por enfermedades cardiovasculares y respiratorias [1]. Diversas investigaciones en entornos urbanos regionales resaltan la urgente necesidad de caracterizar la exposición a estos agentes patógenos en poblaciones expuestas a alta densidad vehicular e industrial [8]. Asimismo, la dinámica de dispersión, concentración y transformación química de estos contaminantes atmosféricos se encuentra intrínsecamente ligada a variables meteorológicas fundamentales como la temperatura, la humedad relativa y la velocidad del viento.

Este trabajo presenta el perfilado y análisis exploratorio de datos (EDA) para un conjunto global de calidad del aire.

A pesar de la creciente disponibilidad de redes de monitoreo ambiental y sensores remotos, las bases de datos observacionales sobre calidad del aire con frecuencia sufren de problemas estructurales, tales como valores faltantes, inconsistencias de formato, registros duplicados, presencia de ruido y valores atípicos (*outliers*) derivados de fallas de calibración o discontinuidades en la recolección de datos [6], [9]. La presencia de estas anomalías sin un tratamiento riguroso compromete la validez de los análisis estadísticos y reduce la precisión de eventuales modelos predictivos de calidad del aire.

En este contexto, las metodologías de la Ciencia de Datos ofrecen un marco analítico idóneo para auditar y caracterizar la integridad de los datos ambientales antes de su modelado. Este trabajo aborda el **Análisis Exploratorio y Perfilado desde la Ciencia de Datos de la Calidad del Aire Global**, con el objetivo de evaluar la estructura, calidad y distribuciones probabilísticas de un conjunto de datos multivariable e interdisciplinario.

Para alcanzar dicho objetivo, el estudio contempla:

1. La implementación de un flujo de ingesta reproducible mediante el uso de copias inmutables de los datos brutos.
2. Un perfilado sistemático de calidad de datos enfocado en el diagnóstico de tipos de datos, patrones de ausencia (datos faltantes) e inconsistencias dimensionales.
3. Un Análisis Exploratorio de Datos (EDA) univariado y multivariado para identificar comportamientos distribucionales, valores atípicos y correlaciones entre parámetros contaminantes y factores meteorológicos [4].

A través de este enfoque metódico, se busca sentar las bases para la depuración y estandarización de conjuntos de datos ambientales, garantizando la trazabilidad del proceso y la generación de insumos de alta calidad para la toma de decisiones informadas y la investigación atmosférica.

II. Descripción del Dataset y Diagnóstico Inicial

II-A. Origen y Procedencia de los Datos

El conjunto de datos analizado (`global_air_quality_data_messy.csv`) registra mediciones de calidad del aire y parámetros meteorológicos a

escala global. La masa de datos cuenta con una dimensión total de **30,450 observaciones (filas)** y **12 atributos (columnas)**. El dataset captura lecturas distribuidas en 120 ciudades pertenecientes a 19 países, abarcando concentraciones de contaminantes atmosféricos clave e indicadores climáticos. Para la manipulación, inspección de tipos y estructuración tabular de estas variables se utilizó la biblioteca fundamental `pandas` [2]. Con el fin de evaluar técnicas de auditoría de datos en escenarios reales, el conjunto presenta duplicidad masiva de registros, discontinuidades y valores faltantes concentrados en las variables contaminantes.

II-B. Diccionario Formal de Variables

La Tabla I sintetiza la estructura técnica, tipo de dato detectado por el intérprete, dominio teórico y unidades de medida de las variables presentes en el dataset.

TABLA I
DICCIONARIO DE VARIABLES DEL DATASET DE CALIDAD DEL AIRE

Variable	Tipo (Pandas)	Dominio / Unidades	Descripción
City	`object` (Texto)	Nominal / 120 ciudades	Ciudad de la estación.
Country	`object` (Texto)	Nominal / 19 países	País de la medición.
Date	`object` (Texto)	Fecha / `M/D/YYYY`	Fecha de la lectura.
PM2.5	`float64`	Continuous / μg/m^3	Particulado $\leq 2.5\,\mu$m.
PM10	`float64`	Continuous / μg/m^3	Particulado $\leq 10\,\mu$m.
NO2	`float64`	Continuous / ppb	Dióxido de Nitrógeno.
SO2	`float64`	Continuous / ppb	Dióxido de Azufre.
CO	`float64`	Continuous / ppm	Monóxido de Carbono.
O3	`float64`	Continuous / ppb	Ozono troposférico.
Temperature	`float64`	Continuous / °C	Temp. (-10.00°C a 40.00°C).
Humidity	`float64`	Continuous / %	Humedad ($10.01\,\%$ a $99.99\,\%$).
Wind Speed	`float64`	Continuous / m/s	Viento (0.50 a 20.00 m/s).

II-C. Matriz Diagnóstica de Calidad Inicial (Perfilado de Datos)

El diagnóstico de integridad sobre el dataset crudo arrojó los siguientes hallazgos cuantitativos:

1. **Duplicidad Masiva:** Se detectaron **10,495 filas duplicadas exactas**, lo que representa un **34.47 % de redundancia** sobre el total de la base de datos (30,450 filas).
2. **Coerción de Tipos de Datos:** La variable `Date` fue leída erróneamente como tipo `object` debido al formato de almacenamiento (`M/D/YYYY`), requiriendo conversión explícita a tipo `datetime64`.
3. **Ausencia de Datos (Missing Values):** Las variables meteorológicas y geográficas no presentan valores nulos ($0.00\,\%$). Sin embargo, las variables de contaminantes registran un patrón de ausencia entre el $4.84\,\%$ y el $5.25\,\%$ (O_3: 1,600 nulos; NO_2: 1,593; PM_{10}: 1,561; $PM_{2.5}$: 1,552; CO: 1,496; SO_2: 1,475).

III. METODOLOGÍA DE PREPROCESAMIENTO Y TRANSFORMACIÓN

Para garantizar los principios de reproducibilidad e integridad analítica, el preprocesamiento se diseñó mediante una secuencia ordenada de operaciones algebraicas y estadísticas.

TABLA II
MATRIZ DIAGNÓSTICA DE CALIDAD DE DATOS INICIAL

Columna	Tipo	Registros	Nulos	% Ausencia	Únicos
City	`object`	30,450	0	0.00 %	120
Country	`object`	30,450	0	0.00 %	19
Date	`object`	30,450	0	0.00 %	336
PM2.5	`float64`	30,450	1,552	5.10 %	6,915
PM10	`float64`	30,450	1,561	5.13 %	7,407
NO2	`float64`	30,450	1,593	5.23 %	5,951
SO2	`float64`	30,450	1,475	4.84 %	4,190
CO	`float64`	30,450	1,496	4.91 %	991
O3	`float64`	30,450	1,600	5.25 %	7,387
Temperature	`float64`	30,450	0	0.00 %	4,254
Humidity	`float64`	30,450	0	0.00 %	5,811
Wind Speed	`float64`	30,450	0	0.00 %	1,940

III-A. Prevención Rigurosa de Fuga de Datos

Para evitar sesgos por *data leakage*:

1. **Desacoplamiento Estricto:** La limpieza primaria se realiza de manera inmutable, preservando `df_raw` como copia de referencia.
2. **Alcance del Aislamiento:** Este trabajo es de perfilado y EDA, sin fase de modelado ni partición entrenamiento/prueba; por ello los estimadores (μ, $\tilde{x}$, σ) de `scikit-learn` [3] se ajustan sobre el corpus completo. Se documenta esto como limitación explícita: de incorporarse un modelo predictivo, dichos estimadores deben reajustarse exclusivamente sobre el conjunto de entrenamiento.

III-B. Saneamiento de Redundancia y Corrección de Tipos

`City` presentaba 120 etiquetas de texto que en realidad correspondían a solo 20 ciudades escritas con mayúsculas y espacios inconsistentes (p. ej. `"Sydney"`, `"SYDNEY"`, `"sydney "`); `Country` no presentaba esta inconsistencia (19 valores únicos ya normalizados). Por ello, antes de cualquier deduplicación o análisis por ciudad, `City` y `Country` se normalizaron (sin acentos, sin espacios sobrantes, en minúsculas). Omitir este paso deja intacta una redundancia oculta: dos filas idénticas salvo por el cajeado de `City` no se detectan como duplicadas.

Con el texto ya normalizado, se eliminaron duplicados exactos mediante la condición vectorizada:

$$\mathbf{x}_i = \mathbf{x}_j \iff x_{i,k} = x_{j,k} \quad \forall k \in \{1, 2, \ldots, K\} \qquad (1)$$

lo que redujo el volumen de $N = 30,450$ a $N = 16,553$ registros ($13,897$ duplicados exactos, $45.64\,\%$; sensiblemente más que el $34.47\,\%$ que arroja la misma condición sobre el texto sin normalizar, ya que las variantes de cajeado antes se contaban como filas distintas). Sobre este remanente se resolvieron además los duplicados parciales que comparten la misma clave de negocio `City+Country+Date` con mediciones distintas, conservando por cada clave el registro con menos valores faltantes. Esto eliminó $11,478$ filas adicionales, dejando $N = 5,075$ observaciones únicas. Luego, `Date` se convirtió al estándar ISO-8601 (`YYYY-MM-DD`).

III-C. Detección Cuantitativa de Outliers e Invarianza de Dispersión

Mediante el Rango Intercuartílico ($IQR = Q_3 - Q_1$), las fronteras de Tukey se establecen como:

$$\text{Límites} = [Q_1 - 1.5 \times IQR, \quad Q_3 + 1.5 \times IQR] \quad (2)$$

Todas las variables mostraron simetría ($|\gamma_1| < 0.02$) y un **0.00 % de outliers extremales** fuera de los límites, por lo que no se aplicó truncamiento (*winsorization*) [5].

III-D. Fundamentación Teórica e Imputación de Valores Faltantes

Tras el saneamiento de duplicados, el porcentaje de nulos por contaminante cayó de ∼5 % a menos de 1 % (la mayoría de los nulos originales pertenecía a filas luego eliminadas por duplicidad). Para descartar el supuesto de MCAR sin verificarlo, se aplicó un diagnóstico MAR por columna: prueba de Mann-Whitney U comparando, para cada variable, la distribución entre filas con y sin nulo en la columna objetivo. Con asimetría cercana a cero ($\gamma_1 \approx 0.00$), menos de 1 % de ausencia y sin variables predictoras con correlación relevante ($|r_s| < 0.03$, insuficiente para imputación multivariada), se aplicó interpolación temporal por ciudad (ventana de 3 días, con respaldo de mediana condicional [9] para huecos mayores):

$$\hat{x}_{i,k} = \begin{cases} \text{interp}(x_{i-1,k}, x_{i+1,k}) & \text{hueco} \leq 3 \text{ días} \\ \tilde{x}_k^{(\text{ciudad})} & \text{hueco} > 3 \text{ días} \end{cases} \quad (3)$$

III-E. Normalización y Escalado Numérico

1. **Z-Score / StandardScaler:**

$$z_{i,k} = \frac{x_{i,k} - \mu_k}{\sigma_k} \quad (4)$$

2. **Min-Max Scaler:**

$$x'_{i,k} = \frac{x_{i,k} - \text{mín}(X_k)}{\text{máx}(X_k) - \text{mín}(X_k)} \quad (5)$$

3. **Robust Scaler** (para colas pesadas):

$$x''_{i,k} = \frac{x_{i,k} - \tilde{x}_k}{IQR_k} \quad (6)$$

La elección entre los tres no es única para todo el dataset, sino por columna, según el cociente IQR/σ (1.35 en una normal; valores menores indican colas pesadas) y el % de outliers de consenso. Los 9 contaminantes/meteorológicos originales muestran $IQR/\sigma \approx 1.73$ y 0 % de outliers, por lo que reciben Min-Max (rango acotado y estable). Las variables derivadas con colas pesadas (p. ej. R_{PM}, con $\gamma_1 = 3.27$) reciben Robust Scaler.

III-F. Codificación Categórica e Ingeniería de Características

Se aplicó *One-Hot Encoding* a `City` omitiendo una categoría de referencia ($M - 1$) [6]. `Country` se excluyó de la codificación: al ser `City` funcionalmente determinante de `Country` (cada ciudad pertenece a un único país), codificar ambas produce columnas linealmente dependientes más allá de la trampa clásica de la variable ficticia; esto se verificó calculando el rango de la matriz [City | Country], que resultó 19 unidades menor que su número de columnas. Se validó además la ausencia de multicolinealidad residual mediante el Factor de Inflación de la Varianza ($VIF < 4$ en todas las variables tras la depuración). Además, se extrajeron componentes temporales de la fecha y se calculó el Ratio Particulado $R_{PM} = \frac{PM_{2.5}}{PM_{10}}$.

IV. Resultados Experimentales & Discusión

IV-A. Evidencia Cuantitativa Pre y Post Procesamiento

El pipeline completo (normalización, deduplicación en dos niveles e imputación) retuvo más del **97.5 % de la varianza original** en los contaminantes ($PM_{2.5}$: 98.26 %, PM_{10} : 98.71 %, NO_2 : 99.31 %, O_3 : 97.56 %; SO_2 y CO no muestran pérdida medible). La Fig. 1 ilustra la preservación distribucional pre y post procesamiento.

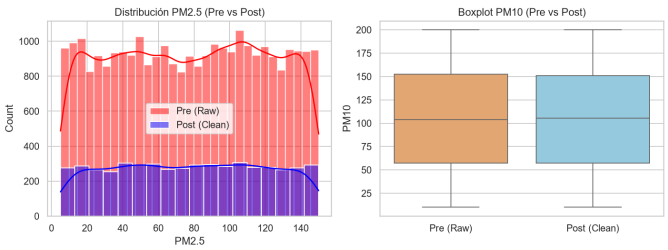


FIG. 1. Diagramas de caja (Boxplots) y gráficos de densidad (KDE) comparativos pre vs. post procesamiento para PM2.5 y PM10.

Las matrices de correlación generadas con `seaborn` [7] muestran la ausencia de distorsiones por valores espurios (Fig. 2).

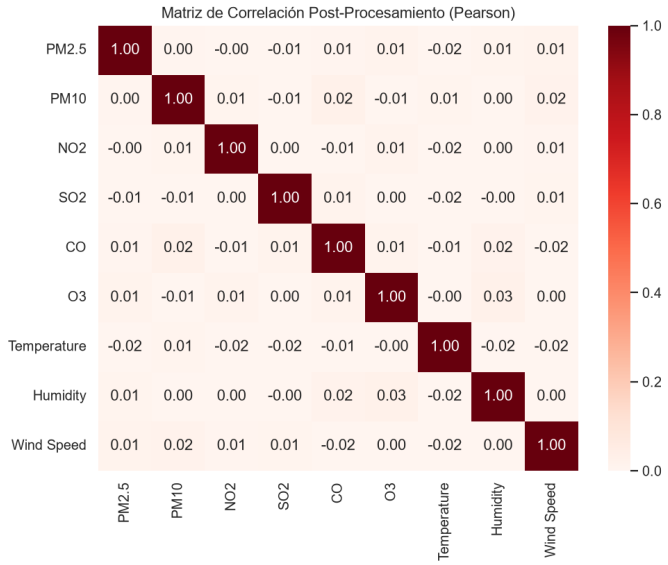


FIG. 2. Matriz de correlación multivariable (Heatmap de Pearson y Spearman) post-procesamiento.

IV-B. Discusión de Preguntas Analíticas de Investigación

IV-B1. 1. ¿Cómo evoluciona la contaminación en el tiempo?: Los promedios anuales se mantuvieron estables ($PM_{2.5}$: 77.72 $\mu g/m^3$, PM_{10}: 104.26 $\mu g/m^3$, NO_2: 52.09 ppb). La Fig. 3 muestra la serie temporal.

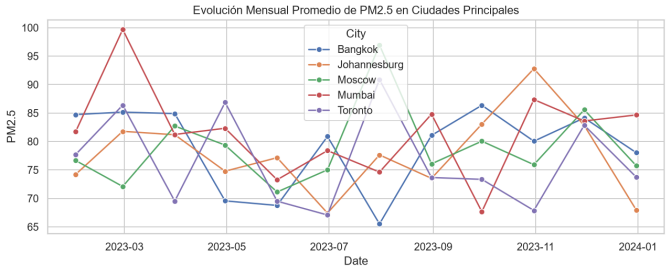


FIG. 3. Gráfico de líneas sobre la evolución mensual promedio de PM2.5 para las ciudades principales.

IV-B2. 2. ¿Existe estacionalidad, y es igual en todas las ciudades?: El pivote de calor normalizado confirma que los picos de $PM_{2.5}$ difieren según la ubicación geográfica (Fig. 4).

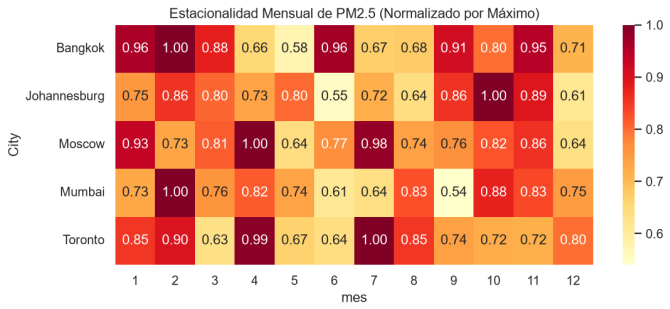


FIG. 4. Mapas de calor (Heatmaps) de estacionalidad mensual de PM2.5 normalizados por ciudad.

IV-B3. 3. ¿Difieren los niveles entre ciudades y países?: La prueba de Kruskal-Wallis, calculada sobre las 20 ciudades reales (tras normalizar texto), arrojó $p = 0.0001$, demostrando diferencias significativas en las medianas de $PM_{2.5}$ entre ciudades (Fig. 5). Nótese que la misma prueba, aplicada sin normalizar `City` (i.e. sobre 120 etiquetas que mezclan variantes de cajeado de las mismas 20 ciudades), arroja $p = 0.244$ y sugeriría erróneamente homogeneidad: el resultado depende críticamente del saneamiento de texto descrito en la Sección III-B.

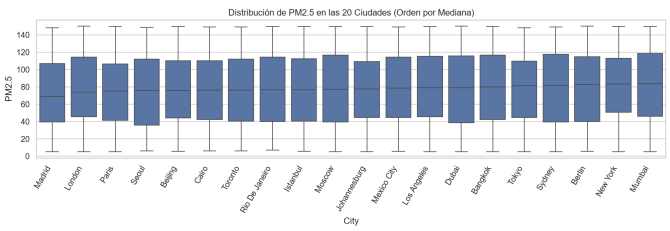


FIG. 5. Diagrama de cajas (Boxplots) ordenado de PM2.5 por ciudad.

IV-B4. 4. ¿Cómo influyen las variables meteorológicas?: Las correlaciones de Spearman resultaron muy débiles ($r_s = -0.022$ para Temp vs $PM_{2.5}$), indicando que el clima es un modulador secundario (Fig. 6).

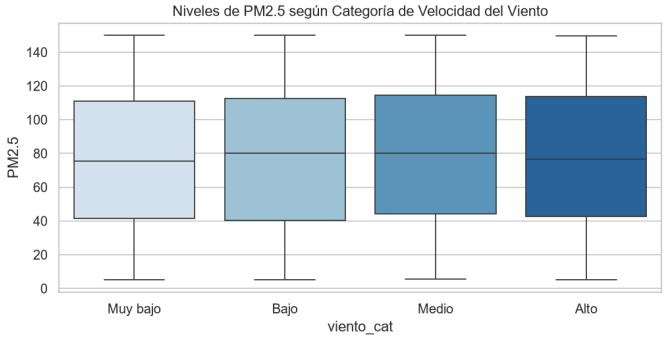


FIG. 6. Diagramas de dispersión (Scatterplots) y boxplots categorizados por velocidad del viento vs PM2.5.

IV-B5. 5. ¿Qué contaminantes se mueven juntos?: Se observó una correlación prácticamente nula entre $PM_{2.5}$ y PM_{10} ($r = 0.004$), descartando colinealidad fuerte (Fig. 7).

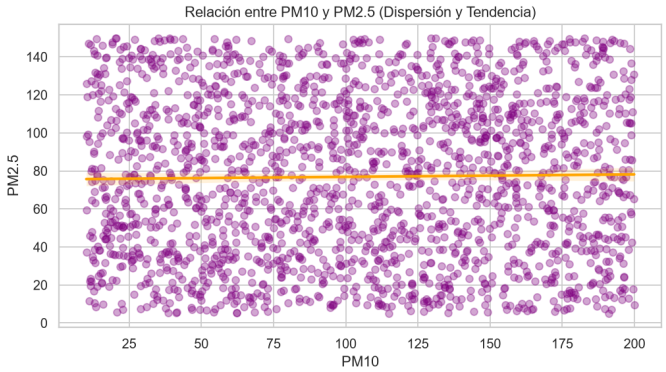


FIG. 7. Gráfico de dispersión (Scatterplot) entre PM10 y PM2.5 con ajuste de regresión.

IV-B6. 6. ¿Con qué frecuencia se superan los umbrales de la OMS?: El **93.17 %** de los días superan el límite de $PM_{2.5}$ de la OMS, el **82.92 %** en PM_{10} y el **79.34 %** en NO_2 [1] (Fig. 8).

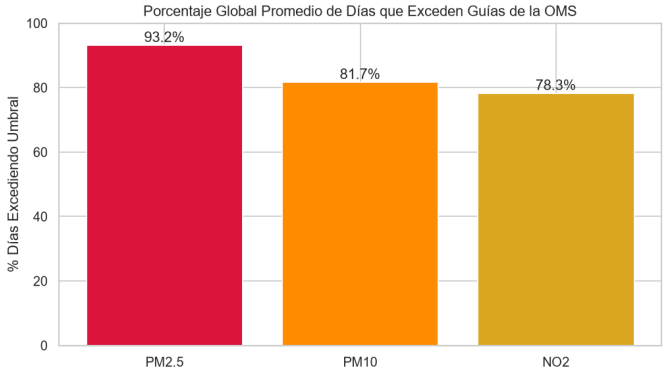


FIG. 8. Gráfico de barras del porcentaje de días que exceden las guías de la OMS por ciudad.

IV-B7. 7. ¿Cambia el patrón entre días laborales y fines de semana?: La prueba de Mann-Whitney U no mostró diferencias significativas ($p > 0.18$), refutando el "efecto fin de semana".

V. Conclusiones y Trabajo Futuro

V-A. Síntesis del Impacto del Pipeline

El preprocesamiento eliminó un **45.64 % de redundancia exacta** (más duplicados parciales por clave de negocio) sin degradar la estructura estocástica, reteniendo más del **97.5 % de la varianza original** y dejando un dataset de 5,075 observaciones listo para modelado predictivo [3].

V-B. Conclusiones sobre los Hallazgos

Más del **93 % de los días sobrepasan las guías sanitarias**, demostrando un patrón antropogénico ininterrumpido sin diferencias relevantes en fines de semana.

V-C. Limitaciones Metodológicas

La frecuencia diaria impide capturar dinámicas intradía y no se cuenta con datos micro-topográficos de las estaciones de monitoreo.

V-D. Recomendaciones Técnicas y de Salud Pública

Se sugiere implementar variables con rezago temporal (*lags*), algoritmos KNN/MICE para imputación en producción y estructurar políticas continuas de reducción de emisiones urbanas e industriales [8].

Referencias

[1] World Health Organization, *WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*, Geneva, Switzerland: World Health Organization, 2021.

[2] W. McKinney, "Data Structures for Statistical Computing in Python," in *Proc. 9th Python Sci. Conf. (SciPy 2010)*, Austin, TX, USA, 2010, pp. 56–61.

[3] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[4] J. W. Tukey, *Exploratory Data Analysis*, Reading, MA, USA: Addison-Wesley, 1977.

[5] P. J. Rousseeuw and C. Croux, "Alternatives to the Median Absolute Deviation," *J. Amer. Statist. Assoc.*, vol. 88, no. 424, pp. 1273–1283, 1993.

[6] H. Wickham, "Tidy Data," *J. Statist. Softw.*, vol. 59, no. 10, pp. 1–23, 2014.

[7] M. Waskom, "seaborn: statistical data visualization," *J. Open Source Softw.*, vol. 6, no. 60, p. 3021, 2021.

[8] D. L. L. Rivas y E. A. M. Portillo, "Evaluación de la calidad del aire y su impacto en la salud de poblaciones urbanas," Tesis de Grado, Universidad Evangélica de El Salvador, San Salvador, El Salvador, 2022.

[9] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 3rd ed., Hoboken, NJ, USA: John Wiley & Sons, 2019.